

Deteksi dan Estimasi Lahan Perkebunan Karet dengan *Deep Learning* Pendekatan *Remote Sensing*

Studi Kasus: Kabupaten Musi Banyuasin, Provinsi Sumatera Selatan

Ahmad Azam Izudin (221810117, 4SD1)

Dosen Pembimbing: Budi Yuniarto, SST, M.Si

Ringkasan— Karet merupakan salah satu hasil komoditas perkebunan Indonesia yang menyumbangkan sebesar 28,9% kebutuhan karet di dunia. Tingginya tingkat produksi karet Indonesia, dikarenakan memiliki luas Tanaman Menghasilkan (TM) yang terbesar di dunia. Pendataan lahan perkebunan karet hanya didapatkan melalui Survei Perusahaan Perkebunan (SKB) yang masih memiliki keterbatasan. *Remote sensing* dapat menjadi alternatif pengumpulan data lahan perkebunan karet karena dapat menghemat tenaga, biaya, dan waktu yang dilakukan pada SKB. Penelitian ini bertujuan untuk mendeteksi lahan perkebunan karet di Kabupaten Musi Banyuasin, Sumatera Selatan menggunakan pita spektral dan indeks komposit citra satelit. Pengambilan data citra satelit menggunakan data dari Landsat-8 dan Sentinel-2 masing-masing sebanyak 1400 titik yang terbagi menjadi tujuh kelas tutupan lahan. Penelitian ini juga membandingkan metode *machine learning* yaitu, *K-Nearest Neighbor* (KNN), *Support Vector Machines* (SVM), *Random Forest* (RF), *Extreme Gradient Boosting* (XGBoost), dan *Logistic Regression* dengan metode *deep learning* yaitu, *Multi-Layer Perceptron* (MLP) dan *Convolutional Neural Network* (CNN) untuk mendapatkan model pengklasifikasian terbaik. Hasil penelitian menunjukkan model RF memberikan hasil terbaik dengan nilai *F1-Score* sebesar 93,42%.

Kata Kunci—Deteksi Karet, *Machine Learning*, *Deep Learning*, *Remote Sensing*.

I. LATAR BELAKANG

Pohon karet (*Hevea brasiliensis*) merupakan tanaman sumber utama karet alam yang menghasilkan lateks dengan sifat elastis dan ketahanan yang tinggi [1]. Sifat tersebut menjadikan karet sebagai bahan utama dalam industri barang konsumsi, otomotif, medis, dan manufaktur [2]. Produksi karet memegang peran yang cukup penting dalam kegiatan perekonomian di negara kawasan *Southeast Asian Nation* (ASEAN) [3]. Berdasarkan data *Food and Agriculture Organization* (FAO), Indonesia berada pada urutan kedua penghasil karet terbesar di dunia dengan total produksi tahunannya sebesar mencapai 3,6 juta ton. Bahkan produksi karet Indonesia dapat memenuhi kebutuhan karet dunia sebesar 28,9% [4]. Hal ini didukung karena memiliki luas TM (Tanaman Menghasilkan) terbesar di dunia. Penyumbang terbesar produksi karet Indonesia berada di Provinsi Sumatera Selatan dengan Kabupaten Musi Banyuasin sebagai salah satu penghasil utama karet [5].

Pengumpulan data lahan perkebunan karet sangat penting untuk diperhatikan agar data yang diperoleh tepat dan akurat.

Pendekatan konvensional untuk mendeteksi lahan perkebunan karet dilakukan melalui Survei Perusahaan Perkebunan (SKB) oleh Badan Pusat Statistik (BPS), dengan metode pencacahan lengkap *self-enumeration* atau input mandiri melalui SEAAP *online* yang diisi oleh pemilik perkebunan dan SKB *online* bagi yang belum melakukan input mandiri. Selain itu, data juga diperoleh dari Direktorat Jendral Perkebunan, Kementerian Pertanian. Data lahan perkebunan karet yang dikumpulkan adalah data luas lahan, jumlah produksi, produktivitas, status tanaman, dan status perusahaan [6]. Selain memakan waktu yang cukup lama, pendekatan konvensional juga menyerap banyak tenaga kerja dan biaya untuk wilayah perkebunan yang luas dan/atau wilayah yang sulit dalam jangkauan pendataan. Pemanfaatan teknologi *remote sensing* dapat digunakan sebagai salah satu alternatif untuk meningkatkan pengumpulan data lahan perkebunan karet.

Kemudahan dalam penggunaan *remote sensing* dalam mengakses data secara gratis membuat teknologi menjadi hal menarik bagi peneliti untuk pengidentifikasian lahan perkebunan karet. Beberapa penelitian [7-12] dapat mendeteksi lahan perkebunan karet dengan menggunakan informasi pita spektral dengan berbagai macam jenis satelit, indeks komposit, dan metode klasifikasi. Setiap jenis citra satelit memiliki resolusi dan pita multispektral yang berbeda, sehingga dapat dilakukan berbagai kombinasi antara citra satelit, pita multispektral, indeks komposit, ataupun metode klasifikasi. Fokus dalam penelitian ini memanfaatkan pita spektral dan indeks komposit untuk memperoleh fitur penciri lahan perkebunan karet, membandingkan metode klasifikasi *machine learning* dengan *deep learning* untuk mendapatkan model terbaik, dan melakukan estimasi luas lahan perkebunan karet.

II. TUJUAN DAN BATASAN PENELITIAN

A. Tujuan

Adapun tujuan penelitian skripsi ini terbagi menjadi tiga, yaitu untuk:

1. Mengidentifikasi fitur terbaik penciri lahan perkebunan karet.
2. Mengidentifikasi model klasifikasi terbaik dalam mendeteksi lahan perkebunan karet.
3. Mengestimasi luas lahan perkebunan karet.

B. Batasan Penelitian

Keterbatasan dari penelitian ini, belum terdapat data resmi yang sesuai membagi wilayah berdasarkan tutupan lahan

menurut titik koordinat perkebunan karet di Indonesia. Selain itu, proses penentuan label dalam proses identifikasi model klasifikasi lahan perkebunan karet terbatas hanya melalui virtual atau secara tidak langsung. Peneliti memanfaatkan citra satelit beresolusi tinggi yang disediakan oleh *Google Earth* dan *Google Street View* pada *Google Maps* serta data pendukung dari geoportal wilayah penelitian untuk memastikan keabsahan label yang digunakan. Peneliti belum bisa melakukan pengecekan lapangan atau *ground checking*, karena keterbatasan sumber daya manusia dan kendala pandemi Covid-19.

III. PENELITIAN TERKAIT

Pemanfaatan metode *remote sensing* atau penginderaan jauh menjadi salah satu metode yang telah diterapkan oleh peneliti dalam pendeteksian lahan perkebunan karet. Peneliti juga

memanfaatkannya dalam pengestimasian luas lahan dan pengklasifikasian tanaman karet. Metode klasifikasi pada citra satelit terbagi menjadi tiga kelompok, yaitu metode statistika konvensional, metode *machine learning* populer, dan metode *deep learning* [6]. Di Indonesia masih terbatas penelitian terkait penginderaan jarak jauh untuk mendeteksi dan mengklasifikasi lahan perkebunan karet yang memanfaatkan teknologi *machine learning*. Selain itu, sampai saat ini, sepengetahuan dan pencarian penulis, klasifikasi yang memanfaatkan *deep learning*, terbukti lebih unggul secara luas pada *computer vision* belum digunakan di Indonesia pada lahan perkebunan karet. Selanjutnya, tabel literatur memuat jurnal penelitian yang bersinggungan dengan topik skripsi ini agar mudah terlihat perbedaan antara masing-masing penelitian yang telah dilakukan sebelumnya dengan penelitian ini.

TABEL I
TABEL PENELITIAN TERKAIT

No	Pengarang, Tahun	Tujuan	Metode	Sumber Data	Daerah Studi
1	Fan et al., 2015 [7]	Mengukur indeks vegetasi berbasis fenologi dan memetakan perkebunan karet	<i>Fenologi (Phenology) Vegetation Index</i>	Landsat-8 OLI	Xishuangbanna, China
2	J. Aziera, et al., 2017 [8]	Mengidentifikasi karet dan analisis informasi dinamika vegetasi pohon karet	<i>Support Vector Machine (SVM)</i>	Landsat-5 TM, Landsat-7 ETM+, Landsat-8 OLI	Kuala Lumpur, Malaysia
3	Dibs et al., 2017[9]	Mengidentifikasi lahan perkebunan karet dan usia karet	<i>Mahalanobis, K-Nearest Neighbor (KNN), dan Decision Tree</i>	SPOT 5	Hulu Selangor, Malaysia
4	S. Gao, et al., 2019 [10]	Mencari pendekatan pemetaan perkebunan karet dan deteksi perubahan perkebunan karet di kawasan tropis	<i>Support Vector Machine (SVM) dan Random Forest (RF)</i>	Landsat-8	Xishuangbanna, China
5	N. Yusof, et al., 2021[2]	Mendeteksi lahan perkebunan karet dan memetakan kawasan perkebunan karet	<i>Support Vector Machine (SVM), Artificial Neural Network (ANN), Spectral Angle Mapper (SAM)</i>	Landsat-8 OLI, Sentinel-2	Kota Tinggi, Malaysia
6	Pradita, Renata (Skripsi), 2021[11]	Mendeteksi lahan perkebunan karet dan estimasi luas tanam dengan model terbaik	<i>Classification And Regression Trees (CART) dan Random Forest (RF)</i>	Landsat-8, Senstinel-2	Kab. Penukal Abab Lematang Ilir, Provinsi Sumatera Selatan, Indonesia
7	Sari et al., 2022 [12]	Mendeteksi lahan perkebunan karet dan kelapa sawit untuk membedakan dengan lahan hutan	<i>Decision Tree</i>	Landsat-8, Sentinel-1	(Barito Timur, Tabalong, Balangan dan Paser), Kalimantan, Indonesia
8	Penelitian ini	Mengidentifikasi fitur dan model terbaik penciri lahan perkebunan karet dan estimasi luas tanam	<i>Machine Learning dan Deep Learning</i>	Landsat-8, Sentinel-2	Kab. Musi Banyuasin, Provinsi Sumatera Selatan, Indonesia

IV. METODE PENELITIAN

A. Wilayah Studi

Sumatera Selatan merupakan provinsi penghasil produksi karet terbesar di Indonesia. Berdasarkan data BPS, pada tahun 2020 tercatat produksi karet sebesar 867.568 Ton atau 28,56% dari total produksi karet nasional. Kabupaten Musi Banyuasin memiliki luas perkebunan karet terluas jika dibandingkan dengan kabupaten dan kota di Sumatera Selatan lainnya yaitu sebesar 207.868 Ha. Oleh karena itu, kabupaten Musi Banyuasin dipilih sebagai *Region of Interest* (ROI) atau studi lokasi.



Gambar 2. Citra Sentinel-2 Kabupaten Musi Banyuasin

B. Pengumpulan Data

a) Data Citra


Data citra diperoleh dari Satelit Landsat-8 *Surface Reflectance Tier 1* dan Sentinel-2 MSI: *MultiSpectral Instrument Level 2A* dengan menggunakan *Google Earth Engine* (GEE). Landsat-8 *Surface Reflectance Tier 1* memiliki resolusi spasial atau akurasi hingga 30 meter dengan resolusi temporal 16 hari sedangkan Satelit Sentinel-2 MSI: *MultiSpectral Instrument Level 2A* memiliki resolusi spasial atau akurasi hingga 10 meter dengan resolusi temporal 10 hari [2]. Selanjutnya dilakukan proses seleksi awan untuk memudahkan proses pelabelan objek. Pada Landsat-8, terpilih citra terbaik pada rentang bulan Juli sampai September tahun 2019 dengan persentase awan 2,42%; 5,25%; 6,51%; 17,37%. Sementara itu, pada Sentinel-2, terpilih citra terbaik pada rentang bulan Agustus sampai November tahun 2019 dengan persentase awan dibawah 10%. Langkah berikutnya dilakukan penggabungan gambar citra menjadi satu dengan batas ROI.

b) Data Sample

Pengambilan titik sampel dibagi menjadi tujuh kelas target yang terdiri dari awan, air, perkebunan karet, perkebunan nonkaret, hutan, bangunan, dan tanah. Sebanyak 1.400 titik sampel diambil dan setiap kelasnya memiliki ukuran yang sama yaitu 200 titik. Data sampel yang diperoleh dibagi secara sama untuk setiap kelasnya.

c) Metode Pemberian Label

Pelabelan dibantu menggunakan alat bantu citra satelit milik *Google Earth*, informasi lokasi sampel dari *Google Earth Engine*, tangkapan kamera *Google Street View*, informasi perkebunan yang terdaftar di *Google Maps* dan data pendukung geoportal Kabupaten Musi Banyuasin. Hal ini disebabkan karena belum tersedianya publikasi data administratif resmi perkebunan karet pada setiap titik-titik koordinat di Indonesia. Perlu diketahui bahwa proses pengambilan titik sampel merupakan tahapan dengan tingkat kesulitan yang paling tinggi, mengingat sulitnya membedakan citra kelas perkebunan karet dengan kelas hutan. Pada Gambar 2, gambar satelit terlihat sangat mirip dan tidak memiliki pola tanam atau keteraturan yang baik, sehingga diperlukan ketelitian yang lebih dalam memilih titik sampel.



Gambar 2. Citra Tutupan Lahan: (a) Perkebunan Karet; (b) Hutan Menggunakan *Google Earth*

C. Pengumpulan Fitur

Koleksi fitur terdiri dari beberapa pita multispektral dan indeks komposit sebagai variabel prediktor. Pita multispektral adalah spektrum atau gelombang elektromagnetik dipancarkan dari citra satelit dengan panjang gelombang tertentu. Hanya tiga gelombang elektromagnetik yang dapat dilihat oleh mata manusia, yaitu merah (*red*), hijau (*green*), dan biru (*blue*) atau RGB. Sementara itu, gelombang lainnya tidak dapat dilihat dengan mata manusia, misalnya *Near-Infrared* (NIR) dan *Short Wave Infrared* (SWIR). Objek amatan akan menyerap spektrum dan nilai masing-masing gelombang akan diproses dan dihitung. Tabel 2 menunjukkan pita multispektral yang digunakan pada penelitian ini.

TABEL II
PITA MULTISPEKTRAL CITRA SATELIT

<i>Sentinel-2</i>	<i>Bands</i>	<i>Wavelength (nanometer)</i>	<i>Resolusi</i>
<i>Blue</i>	B2	490	10 m
<i>Green</i>	B3	560	10 m
<i>Red</i>	B4	665	10 m
<i>NIR</i>	B8	842	10 m
<i>SWIR 1</i>	B11	1610	20 m
<i>SWIR 2</i>	B12	2190	20 m

<i>Landsat-8</i>	<i>Bands</i>	<i>Wavelength (micrometer)</i>	<i>Resolusi</i>
<i>Blue</i>	B2	0.45 – 0.51	30 m
<i>Green</i>	B3	0.53 – 0.59	30 m
<i>Red</i>	B4	0.64 – 0.67	30 m
<i>NIR</i>	B5	0.85 – 0.88	30 m
<i>SWIR 1</i>	B6	1.57 – 1.65	30 m
<i>SWIR 2</i>	B7	2.11 – 2.29	30 m

Indeks komposit dihasilkan melalui transformasi beberapa pita spektral. Biasanya, indeks komposit digunakan untuk tugas tertentu [13]. Indeks komposit vegetasi yang digunakan untuk membedakan kelas perkebunan karet, perkebunan nonkaret, dan hutan, yaitu *Normalized Difference Vegetation Index* (NDVI), *Atmospherically Resistant Vegetation Index* (ARVI) [7], dan *Enhanced Vegetation Index* (EVI) [14]. *Normal Difference Built-up Index* (NDBI) sensitif terhadap lahan bangunan atau lahan terbuka [15]. Sementara itu, untuk daerah genangan air menggunakan *Normalized Difference Water Index* (NDWI).

TABEL III
FORMULA INDEKS KOMPOSIT

<i>Indeks Komposit</i>	<i>Persamaan Band yang digunakan^a</i>
NDVI	$(NIR - Red)/(NIR + Red)$
ARVI	$(NIR - \gamma * Red - Blue)/(NIR + \gamma * Red - Blue)$
EVI-2	$2.5 * (NIR - Red)/(NIR + 2.4 * Red + 1)$
NDBI	$(SWIR1 - NIR)/(SWIR1 + NIR)$
NDWI	$(Green - NIR)/(Green + NIR)$

^aKeterangan mengenai *Band* pada masing-masing satelit dapat dilihat pada Tabel II.

D. Metode Analisis

Analisis deskriptif dilakukan pada pemilihan fitur terbaik menggunakan data pita multispektral dan indeks komposit yang dikelompokkan pada rentang tertentu menggunakan *Jenks Natural Breaks*. *Natural Breaks* merupakan jenis metode klasifikasi optimal yang akan memaksimalkan varians antar kelas dan meminimalkan varians dalam kelas.

Pengelompokkan berdasarkan informasi yang melekat dalam data (*data-driven*). Rentang level terbentuk menjadi 5, yaitu *very low*, *low*, *medium*, *high*, dan *very high* [16]. Pengujian *Goodness of Variance Fit* (GVF) yang menghasilkan nilai mendekati satu menunjukkan pada variasi antar kelas yang dibagi optimum.

Analisis klasifikasi citra menggunakan algoritma *supervised classification* dengan *machine learning* dan *deep learning*. Pada *machine learning*, digunakan algoritma klasifikasi, yaitu *K-Nearest Neighbor* (KNN), *Support Vector Machines* (SVM), *Random Forest* (RF), *Extreme Gradient Boosting* (XGBoost), dan *Logistic Regression*. Sementara itu, *deep learning* menggunakan *Multi-Layer Perceptron* (MLP) dan *Convolutional Neural Network* (CNN-1D). Selanjutnya dilakukan *Stratified Suffle 10-Fold Cross Validation* untuk lebih yakin dalam pemilihan model terbaik.

a) Machine Learning

KNN merupakan metode klasifikasi yang sangat sederhana dalam mengklasifikasikan sebuah data berdasarkan jarak terdekat dengan tetangganya yang mana memiliki karakteristik mirip. Data yang memiliki jarak fitur vektor terdekat akan menjadi satu kelas atau label klasifikasi [17]. SVM merupakan metode *machine learning* yang digunakan untuk data berdimensi tinggi untuk menemukan sebuah batasan yang optimal dalam memisahkan kelas yang satu dengan yang lain. Algoritma ini tidak mudah terjadi *over fitting* dan dapat menghasilkan akurasi tinggi pada model nonlinear yang kompleks [18]. *Random Forest* didefinisikan sebagai perpanjangan dari algoritma *Decision Tree* (CART) dengan menerapkan metode *bootstrap aggregating* (*bagging*) dan pemilihan fitur acak. Kelebihan dari metode ini dapat memproses data dalam jumlah besar, dengan variabel yang banyak, dan sensitif terhadap multikolinieritas maupun *overfitting* [19].

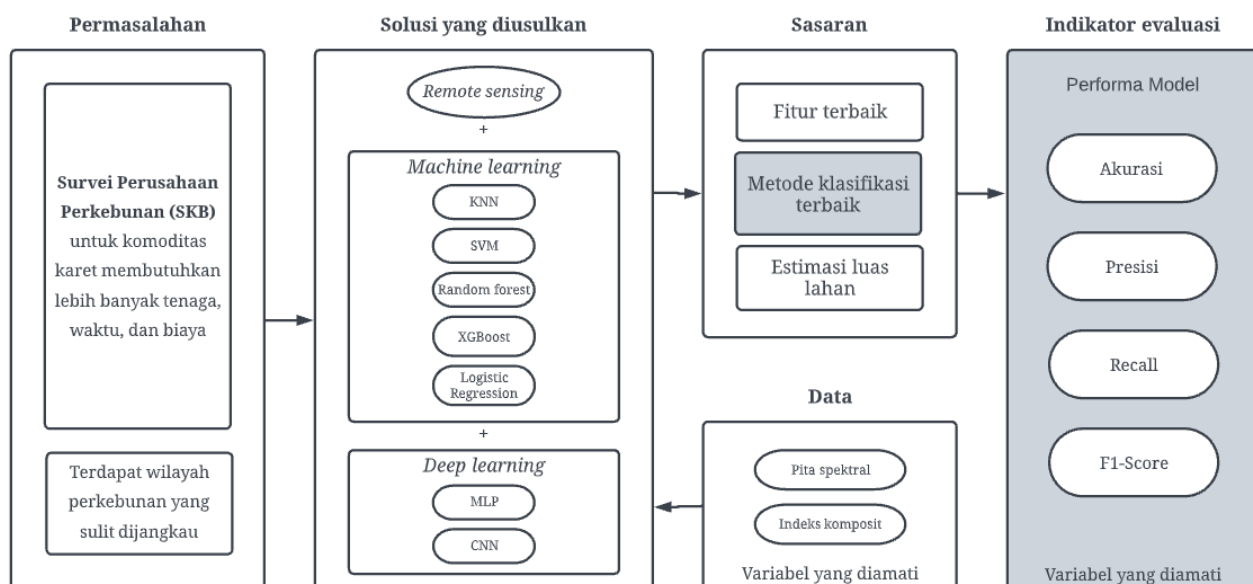
Random Forest dapat menghasilkan akurasi yang sangat baik dan ekstraksi fitur terbukti sangat penting, sehingga dimanfaatkan pada *preprocessing* citra [20]. XGBoost merupakan algoritma *ensemble learning* dengan membuat dan menggabungkan sejumlah besar pengklasifikasi yang lemah namun saling melengkapi untuk menghasilkan estimator yang kuat. Kombinasi ini dapat dibuat dengan dua cara: *bagging* dan *boosting* [21]. *Logistic regression* menentukan hubungan antara *output* yang berupa *binary classification* dengan variabel independen menggunakan probabilitas untuk memprediksi variabel dependen (*sigmoid activation*). Metode ini juga dapat melakukan *multi-class logistic regression* [22].

b) Deep Learning

MLP merupakan model *neural network* yang terdiri dari beberapa *hidden layer* dan *node* antar *layer* saling terhubung satu sama lain [23]. Arsitektur MLP terdiri dari *input layer*, satu atau lebih *hidden layer*, dan *output layer*. CNN merupakan operasi konvolusi penggabungan beberapa lapisan pemrosesan dan menggunakan elemen dalam beroperasi secara paralel yang terinspirasi dari sistem saraf biologis [24]. Arsitektur yang digunakan adalah CNN 1-D. Arsitektur CNN 1-D terdiri dari 3 *layer*, yaitu *convolutional layer*, *pooling layer*, dan *fully connected layer*.

V. KERANGKA PIKIR

Penelitian ini diawali dengan adanya keterbatasan pada metode pengumpulan data pada Survei Perusahaan Perkebunan (SKB) komoditas karet oleh Badan Pusat Statistik yang membutuhkan banyak tenaga, waktu, dan biaya yang besar serta sulitnya mencapai area perkebunan karet. Kerangka pikir pada penelitian ini mengacu pada [25] dan diilustrasikan pada Gambar 3.




Gambar 3. Kerangka Pikir


VI. HASIL DAN PEMBAHASAN

A. Identifikasi Fitur Terbaik Penciri Perkebunan Karet

Seluruh pita multispektral dan indeks komposit Sentinel-2 dan Landsat-8 dinormalisasi dan distandarisasi. Fitur dihitung rata-ratanya lalu diuji GVF untuk setiap fitur. Hasil menunjukkan nilai GVF mendekati satu sehingga dapat dikelompokkan menurut levelnya. Distribusi fitur tiap kelas ditunjukkan dengan *heatmap* pada Gambar 4 dan Gambar 5.



Gambar 4. Rentang Fitur pada Citra Sentinel-2



Gambar 5. Rentang Fitur pada Citra Landsat-8

Berdasarkan *heatmap* Gambar 4 dan Gambar 5, diperoleh informasi mengenai perbedaan nilai *band* pada tiap-tiap kelas. Nilai rata-rata pita spektral atau *band* bawaan dari Sentinel-2 ataupun Landsat-8 hampir tidak ada perbedaan antar kelas atau serupa, sehingga sulit untuk membedakan kelas-kelas. Oleh karena itu, indeks komposit yang merupakan kombinasi dari beberapa *band* yang ada digunakan. Penciri perkebunan karet didapatkan nilai yang serupa, baik Sentinel-2 ataupun Landsat-8, misalnya pada fitur RGB, SWIR2, dan NDWI berada pada level *very low*, fitur NIR dan SWIR1 berada pada level *low*. NDBI berada pada level *medium*. Indeks vegetasi NDVI, EVI, dan ARVI berada pada level *very high*, namun pada Sentinel-2 berada pada level *medium*.

NDBI mudah untuk membedakan kelas bangunan dan tanah dengan kelas lainnya, ditandai dengan perolehan nilai yang tinggi. NDWI juga mampu untuk membedakan kelas air

dengan kelas lain, tetapi tidak untuk kelas awan. Hal ini sudah diatasi dengan menggunakan NDBI yang mendapatkan kelas air yang berada pada level *low* dan kelas Awan pada level *high*. Selain itu, NDWI mampu membedakan kelas bangunan dan kelas tanah berurutan menghasilkan nilai level *low* dan level *medium*. Dilain sisi pada indeks vegetasi NDVI, EVI, dan ARVI belum bisa membedakan kelas perkebunan karet, perkebunan nonkaret, dan hutan baik pada Sentinel-2 ataupun Landsat-8. Namun jika diperhatikan lebih lanjut, dapat dilihat bahwa keduanya memiliki pola, bahwa kelas perkebunan karet memiliki nilai yang lebih rendah daripada kelas perkebunan nonkaret ataupun hutan pada indeks vegetasi dan nilai yang lebih tinggi pada NDBI dan NDWI. Dengan menggabungkan informasi ini, mesin mungkin akan mampu membedakan antara kelas tersebut. Dengan begitu, bila nilai indeks suatu *pixel* berada pada level yang sama untuk kelas perkebunan karet, perkebunan nonkaret, dan hutan, nilai yang paling rendah di NDVI, EVI, dan ARVI tetapi lebih tinggi di NDBI dan NDWI kemungkinan besar *pixel* tersebut mewakili perkebunan karet.

B. Identifikasi Model Terbaik Deteksi Lahan Perkebunan Karet.

Berikut performa dari model *machine learning* dan model *deep learning* yang digunakan, serta perbandingannya dapat dilihat pada Tabel VI. Tabel tersebut menunjukkan hasil *stratified suffle 10-fold cross validation* beserta optimasi *hyperparameter* pada *machine learning* yang dicari menggunakan *grid search*.

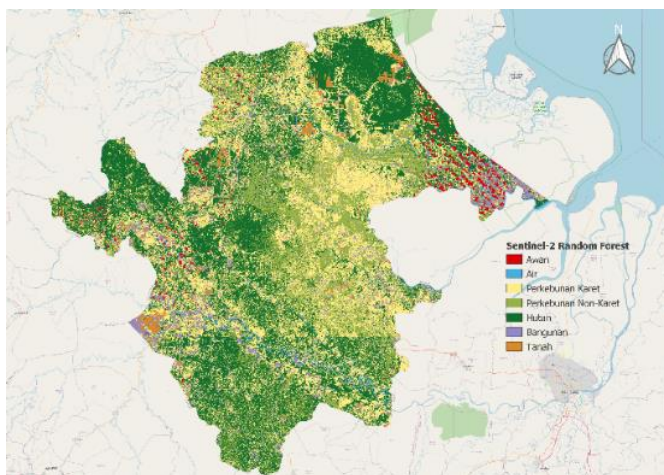
TABEL IV
PERBANDINGAN PERFORMA MODEL MENGGUNAKAN
STRATIFIED SUFFLE 10-FOLD CROSS VALIDATION.

Citra Satelit	Algoritma	Accuracy	Precision	Recall	F1-Score
Sentinel-2	KNN	89,21%	89,63%	89,21%	89,14%
	SVM	92,50%	92,89%	92,50%	92,46%
	Random Forest	93,43%	93,68%	93,43%	93,42%
	XGBoost	93,36%	93,68%	93,36%	93,37%
	Logistic Regression	87,71%	88,04%	87,71%	87,67%
	MLP	91,35%	91,35%	53,43%	65,96%
	CNN	90,12%	90,12%	89,29%	89,70%
Landsat-8	KNN	89,14%	89,70%	89,14%	89,11%
	SVM	92,29%	92,63%	92,29%	92,29%
	Random Forest	90,71%	91,10%	90,71%	90,70%
	XGBoost	91,14%	91,42%	91,14%	91,13%
	Logistic Regression	88,21%	88,48%	88,21%	88,15%
	MLP	82,60%	82,60%	58,14%	72,49%
	CNN	90,50%	90,50%	88,50%	89,49%

Hasil menunjukkan bahwa, algoritma *Random Forest* mendapatkan persentase tertinggi di seluruh aspek penilaian, yaitu *Accuracy* sebesar 93,43%; *Precision* sebesar 93,68%; *Recall* sebesar 93,43%; *F1-Score* 93,42% pada Sentinel-2. Sementara itu, pada Landsat-8 diperoleh algoritma SVM dengan penilaian persentase tertinggi, yaitu *Accuracy* sebesar 92,29%; *Precision* sebesar 92,63%; *Recall* sebesar 92,29%; *F1-Score* 92,29%. Algoritma *Logistic Regression* mendapatkan persentase terendah jika ditinjau dari nilai akurasi pada kedua

citra satelit, baik Sentinel-2 maupun Landsat-8. Persentase *Accuracy* sebesar 87,71% pada Sentinel-2, sedangkan pada Landsat-8 mendapat persentase *Accuracy* sebesar 88,21%. Selain itu, algoritma MLP mendapatkan persentase nilai terendah berdasarkan nilai *F1-Score*, yaitu sebesar 65,96% pada Sentinel-2 dan sebesar 72,49% pada Landsat-8. Beberapa algoritma menunjukkan hasil performa lebih baik pada penggunaan data citra Sentinel-2 daripada data citra Landsat-8. Hal yang bisa menyebabkan hal ini adalah resolusi yang digunakan, Sentinel 2 memiliki resolusi 10 meter sementara Landsat 8 memiliki resolusi 30 meter.

Berdasarkan penjelasan diatas, hasil model terbaik dipilih algoritma *Random Forest* pada Sentinel-2. Berikut peta tutupan lahan Kabupaten Musi Banyuasin berdasarkan hasil klasifikasi yang ditunjukkan pada Gambar 6.



Gambar 6. Peta Tutupan Lahan Kabupaten Musi Banyuasin

VII. PENUTUP

A. Kesimpulan Sementara

Menjawab tujuan pertama penelitian untuk mengidentifikasi fitur penciri lahan perkebunan karet terhadap kedua citra satelit terdiri dari NDVI, EVI, dan ARVI yang memiliki nilai lebih rendah, namun memiliki nilai yang lebih tinggi pada NDBI dan NDWI daripada kelas perkebunan nonkaret ataupun hutan. Selanjutnya menjawab tujuan kedua penelitian untuk mendapat model terbaik klasifikasi dengan menggunakan algoritma *Random Forest* pada citra satelit Sentinel-2 dengan nilai *Accuracy*, *Precision*, *Recall*, dan *F1-Score* tertinggi.

B. Rencana Selanjutnya

Berdasarkan kesimpulan sementara, peneliti akan melakukan beberapa hal:

- 1) Melakukan *hyperparameter tuning* pada metode *deep learning* dengan harapan menaikkan nilai *F1-Score*.
- 2) Melanjutkan tujuan ketiga, yaitu melakukan estimasi lahan perkebunan karet berdasarkan model terbaik dan membandingkannya dengan data *official statistics*.

DAFTAR PUSTAKA

- [1] G. Chen, J. C. Thill, S. Anantsuksomsri, N. Tontisirin and R. Tao, "Stand age estimation of rubber (*Hevea brasiliensis*) plantations using an integrated pixel and object based tree growth model and annual Landsat time series," *ISPRS Journal of Photogrammetry and Remote Sensing*, pp. 94-104, 2018.
- [2] N. Yusof, H.Z.M. Shafri, & N.S.N. Shaharum, "The use of Landsat-8 and Sentinel-2 imageries in detecting and mapping rubber trees," *J Rubber Res* 24, pp. 121-135, 2021.
- [3] N. Somching, S.Wongsai, N.Wongsai, and W.Koedsin, "Using machine learning algorithm and landsat time series to identify establishment year of para rubber plantations: a case study in Thalang district, Phuket Island," *Thailand, International Journal of Remote Sensing*, 41:23, pp. 9075-9100, 2020.
- [4] Iqbal Hakim. (2020). 10 Negara Penghasil Karet Terbesar di Dunia. [Online]. Available: <https://insanpelajar.com/10-negara-penghasil-karet-terbesar-di-dunia/>
- [5] Badan Pusat Statistik Provinsi Sumatera Selatan, "Statistik Perkebunan Provinsi Sumatera Selatan 2016-2020," *Badan Pusat Statistik Provinsi Sumatera Selatan*, 2021.
- [6] Direktorat Statistik Tanaman Pangan, Hortikultura, dan Perkebunan, "Statistik Karet Indonesia 2020," *Badan Pusat Statistik*, 2021.
- [7] H. Fan, X. Fu, Z. Zhang, and Q. Wu, "Phenology-based vegetation index differencing for mapping of rubber plantations using landsat OLI data," *Remote Sensing*, vol. 7, no. 5, pp. 6041-6058, 2015.
- [8] J. Aziera, A. Rashid, Noordin and M. I. Sameen, "Mapping rubber trees based on phenological analysis of Landsat time series data-sets," *Geocarto International*, pp. 627-65, 2017.
- [9] H. Dibs, M. O. Idrees, and G. B. A. Alsallhin, "Hierarchical classification approach for mapping rubber tree growth using per-pixel and object-oriented classifiers with SPOT-5 imagery," *Egyptian Journal of Remote Sensing and Space Science*, vol. 20, no. 1, pp. 21-30, Jun. 2017.
- [10] S. Gao, X. Liu, Y. Bo, Z. Shi, dan H. Zhou, "Rubber Identification Based on Blended High Spatio Temporal Resolution Optical Remote Sensing Data: A Case Study in Xishuangbanna," *Remote Sensing*, pp. 496, 2019.
- [11] P. Renata, A. W. Wijayanto, "Estimasi Luas Lahan Perkebunan Karet dengan Metode Penginderaan Jauh dan Machine Learning Studi Kasus: Kabupaten PALI, Provinsi Sumatera Selatan". *Politeknik Statistika STIS*. 2021
- [12] I. L. Sari, C. J. Weston, G. J. Newnham, and L. Volkova, "Developing multi-source indices to discriminate between native tropical forests, oil palm and rubber plantations in indonesia," *Remote Sensing*, vol. 14, no. 1, Jan. 2022.
- [13] T.Hoeser, F. Bachofer, and C. Kuenzer, "Object detection and image segmentation with deep learning on earth observation data: A review— part II: Applications," *Remote Sensing*, vol. 12, no. 3053, 18 Sep 2020.
- [14] A. D. R. Wijaya, Hani'ah, dan N. Bashit, "Studi Perbandingan Metode Arvi, Evi 2 Dan Ndivi Untuk Penentuan Kerapatan Tajuk Dalam Identifikasi Lahan Kritis Di Kabupaten Boyolali (Studi Kasus: Kecamatan Ampel, Kecamatan Cepogo, Kecamatan Selo dan Kecamatan Musuk Kabupaten Boyolali)," *Jurnal Geodesi Undip*, vol. 08, no. 1, 2019.
- [15] I. N. Hidayati, R. Suharyadi, dan P. Danoedoro, "Developing an Extraction Method of Urban Built-Up Area Based on Remote Sensing Imagery Transformation Index," *Prosiding Seminar Nasional Geografi UMS VIII*, 2018.
- [16] N. Verde, I. P. Kokkoris, C. Georgiadis, D. Kaimaris, P. Dimopoulos, I. Mitsopoulos, and G. Mallinis, "National scale land cover classification for ecosystem services mapping and assessment, using multitemporal Copernicus EO data and Google Earth Engine," *Remote Sensing*, vol. 12, no. 3303, 11 Okt. 2020.
- [17] F. Lia, "Implementasi K-Nearest Neighbor Untuk Klasifikasi Bunga Dengan Ekstraksi Fitur Warna RGB," *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIIK)*, vol. 07, no. 6, Des 2020.
- [18] Y. Chen, P. Dou, and X. Yang, "Improving land use/cover classification with a multiple classifier system using AdaBoost integration technique," *Remote Sensing*, vol. 9, no. 10, 2017.
- [19] D. W. Triscowati, B. Sartono, A. Kurnia, D. D. Domiri, and A. W. Wijayanto, "Multitemporal remote sensing data for classification of food crops plant phase using supervised random forest," in *the Sixth Geoinformation Science Symposium, International Society for Optics and Photonics. Yogyakarta: SPIE*, 2019.
- [20] W. Nanik, A. Srifah, "Random Forest Classifier untuk Deteksi Penderita COVID-19 berbasis Citra CT Scan," *Jurnal Teknik Komputer AMIK BSI*, vol 07, no.2, 2021.
- [21] L. Torlay, M. Perrone-Bertolotti, E. Thomas, and M. Baci, "Machine learning-XGBoost analysis of language networks to classify patients with epilepsy," *Brain Informatics*, vol. 4, no. 3, pp. 159-169, Sep. 2017.
- [22] M. S. T. Putra dan Y. Azhar, "Perbandingan Model Logistic Regression dan Artificial Neural Network pada Prediksi Pembatalan Hotel," *Jurnal Informatika Sunan Kalijaga*, vol. 06, no. 1, pp. 29 - 37, 2021.
- [23] W. Jiang et al., "Multilayer perceptron neural network for surface water extraction in landsat 8 OLI satellite images," *Remote Sens.*, vol. 10, no. 5, pp. 1-22, 2018.
- [24] F. Hu, G. S. Xia, J. Hu, and L. Zhang, "Transferring deep Convolutional Neural Networks for the scene classification of high-resolution remote sensing imagery," *Remote Sensing*, vol. 7, no. 11, pp. 14680-14707, 5 Nov 2015.
- [25] M. Berndtsson, J. Hansson, B. Olsson, dan B. Lundell, "Thesis Projects— A Guide for Students in Computer Science and Information System 2nd Edition," *London: Springer*, 2008.